

IRC ROBOTIQUE 2026

23 JANVIER 2026

CPÉTARD



BOZON CHERIF GROS



NOUS CONSTRUISONS LE FUTUR

Un assistant virtuel prévu pour répondre aux attentes des élèves de CPE.

+ 30

Documents de
l'école
traités

-2

Secondes de
latence


+544

Heures de
travail

- Tout doit fonctionner localement
- RAG : Retrieval-augmented generation
- Mettre en place le projet sur deux architectures
- GX10 : **aarch**
- Supercalculateur : **amd**





Accelerated by
 **NVIDIA**



FONCTIONNEMENT RECHERCHÉ

- Détecter un utilisateur
- Le reconnaître
- Commencer une interaction
- écouter pour continuer.



- Sauvegarde des données localement
- Reconnaissance faciale
- Capteur de distance pour activer le système uniquement si besoin.



RAG OU FINETUNING ?

RAG :

- Données récente et maîtrisée
- Mise à jour facilité
- Meilleur tracabilité du raisonnement du LLM (avec citation des sources)

Finetuning :

- Nécessite un dataset conséquent
- Lent
- Grande propabilité d'hallucinations
- Difficile à mettre à jour (nécessite un nouvel entraînement)

CHOIX FINAL : RAG

Fiche technique :

- Modèle : Mistral-Nemo-Instruct-2407 (Les modèles instructs sont idéal pour du RAG)
- Ressources : ~ 20go de VRAM (90% du GPU)
- Freedom : 0.1/1 (le modèle ne va pas chercher à être "original")